

Klasifikacija gljiva korišćenjem neuronskih mreža

Teodora Heldrih

Anđela Karakaš

Uvod

Skup za klasifikaciju gljiva ima 23 atributa, od kojih 22 opisuju osobine gljiva, a klasa je da li je pečurka jestiva ili otrovna. U skupu nema nedostajućih vrednosti. Za klasifikaciju su korišćeni svi atributi, osim veil-type jer on ima samo jednu vrednost, pa ne utiče na klasifikaciju.

Za klasifikaciju jestivosti gljiva običnom neuronskom mrežom je korišćen jezik python3 i Keras – API za neuronske mreže na TensorFlow biblioteci, kao i druge numeričke biblioteke. Klasifikacija sa uprošćenom fuzzy artmap neuronskom mrežom je otkucana ručno u python3, uz pomoć numeričkih biblioteka.

Obična neuronska mreža

Obična neuronska mreža se sastoji iz ulaznog, izlaznog i proizvoljnog broja skrivenih slojeva između. Ona prima ulaz, vrši neke numeričke proračune i daje neki izlaz koji se posle proverava sa željenim izlazom. Zatim se meri funkcija gubitka i na osnovnu gradijentnog spusta se mreža uči da daje bolje rezultate.

Pošto smo se bavili binarnom klasifikacijom, za fju gubitka smo koristili binarnu unakrsnu entropiju, jer ona upoređuje neke verovatnoće koje ćemo dobiti sigmoidnom aktivacionom fjom na izlaznom sloju.

30% skupa je uzeto za test.

Prvo smo napravili 2 skrivena sloja sa relu aktivacionom funkcijom i 16 skrivenih jedinica. 16 skrivenih jedinica je

izabrano jer je blizu 21, tj. broju atributa koji učestvuju u klasifikaciju, pa smo verovali da su dovoljno sposobni da prikažu kompleksnost ulaza. Funkcija aktivacije za izlazni sloj je uzeta sigmoidna funkcija.

Čvorovi su se ažurirali nakon 80 instanci.

Nakon 5 epoha, dobili smo tačnost od 0.9998 nakon treninga i ovaj model je tačno klasifikovao sve instance u testu.

Ako se čvorovi ažuriraju nakon 20 instanci, u 4. epohi je dostignuta tačnost trening skupa od 100%, a u test setu su sve instance tačno klasifikovane. Isto se desilo ako se čvorovi ažuriraju nakon 40 instanci.

Sada smo stavili po 4 skrivene jedinice u 2 skrivena sloja, a čvorovi se ažuriraju nakon 20 instanci. Preciznost trening skupa je 0.9989, a 3 instance su pogrešno klasifikovane. Ako dodamo još jedan skriven sloj sa 4 jedinice, test skup je ceo dobro klasifikovan. Ako ostavimo samo jedan skriveni sloj, 5 instanci nije dobro klasifikovano.

Ako stavimo 2 skrivena sloja sa po 32 jedinice, već u drugoj epohi dobijamo tačnost od 100% na trening skupu, ali ona opada, pa je opet od 4 konstantno 100%. Test skup je ceo tačno klasifikovan. Ako prekinemo trening posle 2 epohe, dobijamo tačnost od 0.9993 na trening skupu, a na test skupu 0.9991, odnosno 2 instance su loše klasifikovane, tj. desilo se blago preprilagođavanje.

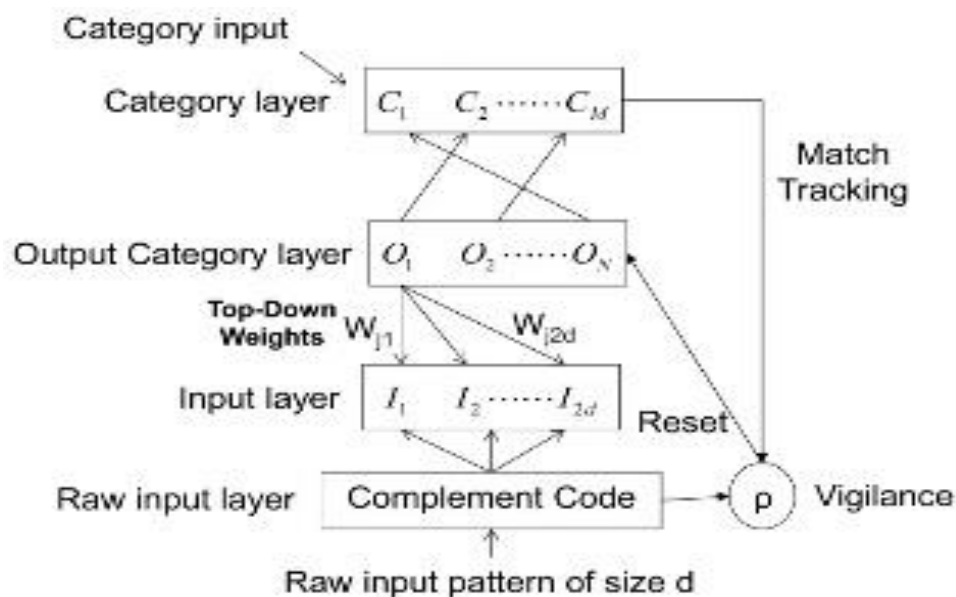
Dakle, idealno imamo 16 jedinica u 2 skrivena sloja i izlazni sloj koji izbacuje verovatnoću. Šta će se desiti ako povećamo test skup? Od 3. epohe je preciznost na trening skupu 100%, a

nakon 5 isto i na test skupu. Ako smanjimo test skup, nakon treće epohe imamo tačnost od 100% na trening skupu, a nakon 5 i na test skupu. Identično se desi i ako je pola skupa za test, a pola za trening.

Simplified Fuzzy ARTMAP

Fuzzy ARTMAP je neuronska mreža koja susreće dve oblasti, fuzzy logiku i adaptive resonance theory. Koristi komplementarno kodiranje kao normaizaciju.

Pojednostavljen fuzzy artmap se može koristiti samo za klasifikaciju, za razliku od fuzzy artmapa, koji može da se koristi i za klasterovanje.



Za razliku od običnih neuronskih mreža, čiji su modeli zasnovani na greškama, fuzzy artmap model je zasnovan na prototipovima, koji se kreiraju po potrebi. Cilj je da ulaz bude što sličniji prototipu.

Mreža se sastoji iz ulaznog sloja, koji je u formatu komplementnog koda i izlaznog sloja koji kodira klasu. Cilj je da čvorovi budu što sličniji ulazu. Značajni parametri mreže su parametar budnosti ρ , stopa učenja β i parametar odabira α . Implementirano je takozvano brzo učenje, odnosno β je 1. U zavisnosti od parametra budnosti, što je veći, kreira se i više kategorija.

ALGORITAM:

1. Prvo se parametar budnosti postavlja na svoju inicijalnu vrednost. Mi smo menjali ovaj parametar od 0 do 1.
2. Zatim se računa fja odabira:

$$T_j(I) = \frac{|I \wedge w_j|}{\alpha + |w_j|},$$

gde je \wedge fuzzy I operator koji se definiše kao

$$(p \wedge q) = \min(p_i, q_i),$$

a norma vektora:

$$|p| = \sum_{i=1}^M |p_i|$$

3. Sada tražimo pobedničkog neurona:
 $J = \max T_j$
4. Zatim se proverava da li je pobednički neuron dovoljno sličan ulazu:

$$\frac{|I \wedge w_j|}{|I|} \geq \rho$$

Ako nije, uzeti sledećeg neurona pobednika.

5. Ako jeste, proveriti da li je klasa neurona pobednika ista kao i klasa koju treba predvideti za ulaz.

Ako jeste, onda se novi neuron postavlja:

$$w_j^{(novi)} = \beta(I \wedge w_j^{(stari)}) + (1 - \beta)w_j^{(stari)}$$

i idi na korak 9.

Ako nije, privremeno povećati parametar budnosti i proveriti sledećeg pobednika.

6. Ako je parametar budnosti veći od 1, prekinuti trening za tu epohu za tu instancu i otići na korak 1.
Ako nije, uzeti sledećeg pobednika.
7. Ovaj korak je za neopredeljenog neurona, dakle ako je pobednik neopredeljen, onda postaviti klasu trenutnog ulaza na klasu pobedničkog neurona, ulaz postaviti za njegove čvorove i kreirati novi neopredeljen neuron.
8. Ponoviti algoritam za sledeći ulaz.

Rezultati:

Train size/ rho	100	1000	2500	Whole sample
0	95%, 6	99,88%, 7	99,88% 7	100%, 8
0.25	95%, 6	99,88%, 9	99,88%, 9	100%, 10
0.5	97,33%, 10	99,55%,16	99,88%, 16	100%, 16
0.75	97%, 18	99,8%, 26	99,91%, 26	100%, 26
1	96,51%, 100	99,8%, 1000		

Na slici se vide rezultati izvršavanja algoritma u jednoj epohi. Uvek je postignuta 100% tačnost na trening skupu, a u tabeli se vidi tačnost u test skupu i broj kreiranih neurona u zavisnosti od instanci uzetih za trening. Vidimo da nekad više kategorija, odnosno napravljenih neurona može poboljšati klasifikaciju, ali nekad je može i pogoršati, ako nemamo previše reprezentativan uzorak, kao kad uzmemo samo 100 instanci. Vidi se i da što je veći parametar budnosti, dobija se i više kategorija.

Dakle, ako se za trening skup uzme 70% celog skupa, moguće je sa fuzzy artmap sve test instance pravilno klasifikovati, nevezano za broj klasa koje se kreiraju.

Literatura

- Chollet, F. (2018). Deep learning with python. Manning Publications Co.
- A Fast Simplified Fuzzy ARTMAP Network, Mohammad-Taghi Vakil-Baghmisheh and Nikola Pavešić, 2003., 273–316
- Primjena Fuzzy ARTMAP neuronske mreže za indeksiranje i klasifikaciju dokumenata, Stjepan Buljat, 2005.
- ARTMAP: Supervised Real-Time Learning and Classification of Nonstationary Data by a Self-Organizing Neural Network, Gail A. Carpenter, Stephen Grossberg, and John H. Reynolds, 1991. , 565-588